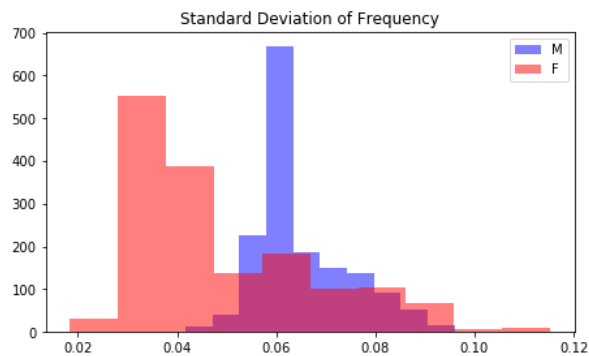


# Exercícios de Fixação de Conceitos 2 - EFC2 - IA048

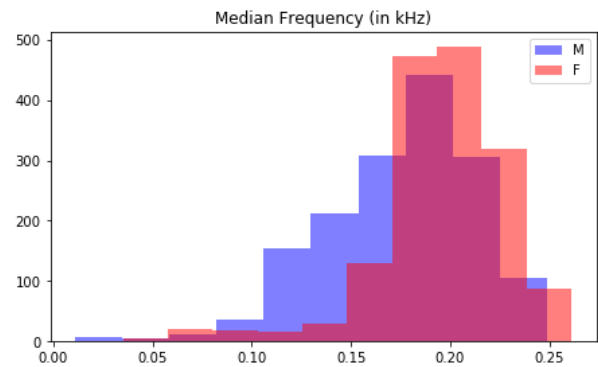
Marcelo Eduardo Pederiva RA: 122580

## Parte 1 - Classificação Binária

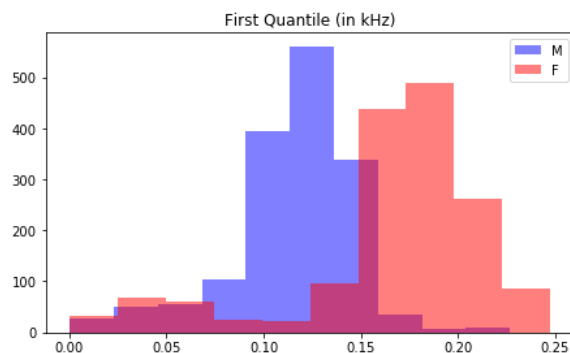
a)



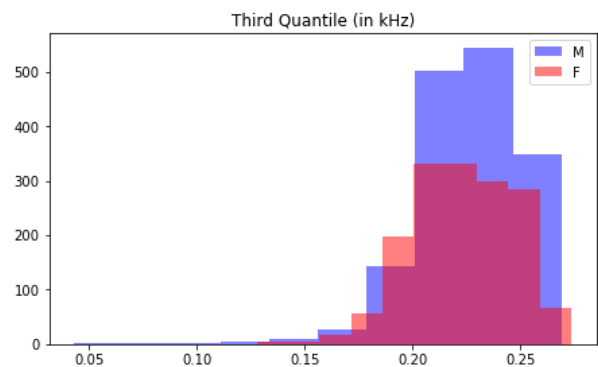
(a) Standart Deviation of Frequency.



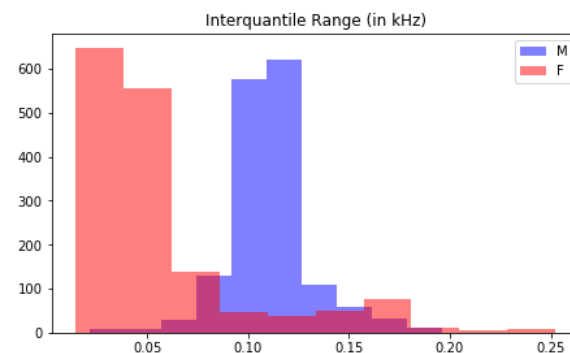
(b) Median Frequency.




(c) First Quantile.



(d) Third Quantile.

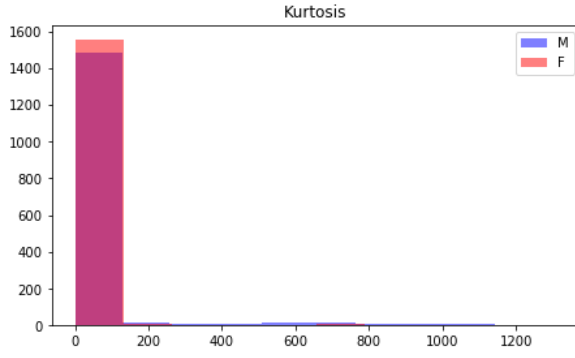


(e) Interquantile Range.

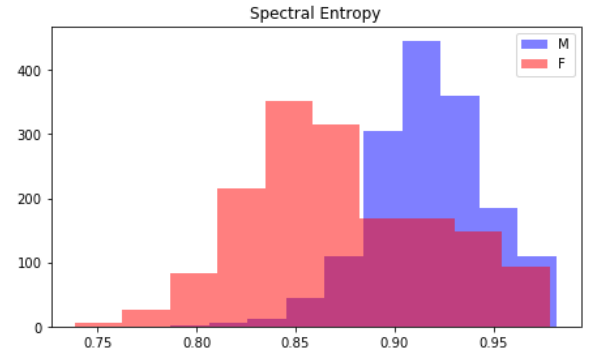


(f) Skewness.

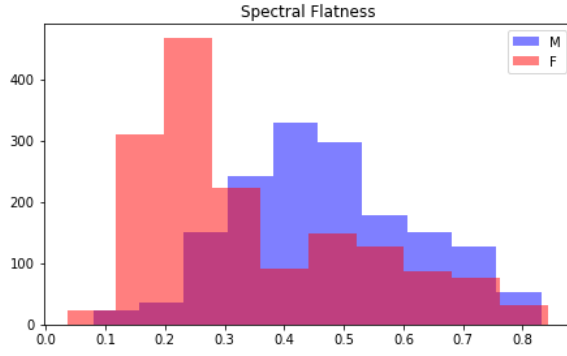
Figura 1: Histogramas



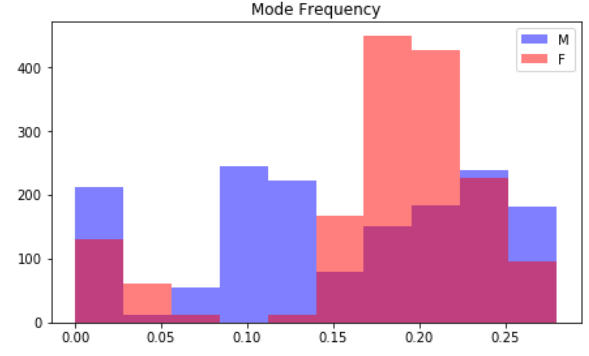
(a) Kurtosis.



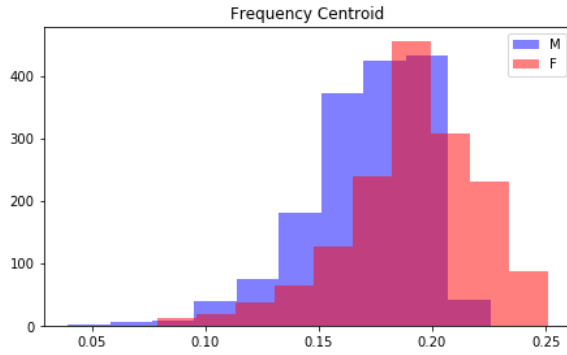
(b) Spectral Entropy.



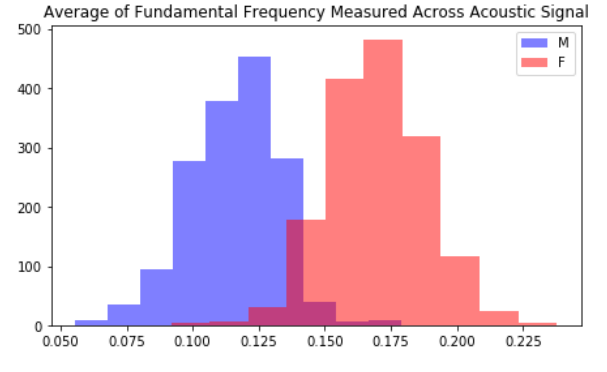
(c) Spectral Flatness.




(d) Mode Frequency.




(e) Frequency Centroid.



(f) Average of Fundamental Frequency Measured Across Acoustic Signal.




(g) Minimum of Fundamental Frequency Measured Across Acoustic Signal.




(h) Maximum of Fundamental Frequency Measured Across Acoustic Signal.

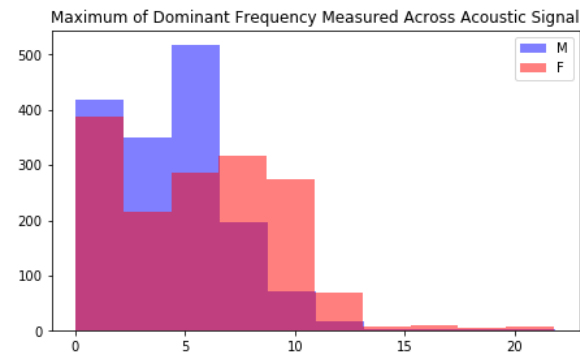
Figure 2: Histogramas




(a) Average of Dominant Frequency Measured Across Acoustic Signal.



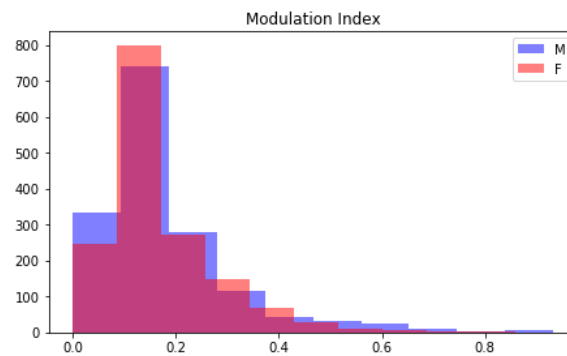
(b) Minimum of Dominant Frequency Measured Across Acoustic Signal.



(c) Maximum of Dominant Frequency Measured Across Acoustic Signal.



(d) Range of Fundamental Frequency Measured Across Acoustic Signal.



(e) Modulation Index.

Figura 3: Histogramas

Podemos observar nos histogramas acima as características de cada gênero. Na maioria dos dados, os histogramas apresentam um mesmo resultado tanto para a voz masculina como para a voz feminina. Entretanto, a análise de algumas características permitem a distinção clara do gênero da voz observado. Esta análise pode ser encontrada em algumas medidas, como:

- Desvio padrão de frequência (Fig. 1a)
- Primeiro quantil (Fig. 1c)
- Intervalo Interquantil (Fig. 1e)
- Entropia Espectral (Fig. 2b)
- Média da frequência fundamental medida através do sinal acústico (Fig. 2f).

Dentre estas medidas, algumas possuem uma maior distinção entre gêneros que as outras.

**b)**

Nessa etapa do projeto foi separado 20% dos dados para validação, enquanto os outros 80% foram utilizados para treinamento do modelo de Regressão Logística.

Seguindo para a etapa de treinamento, os dados foram normalizados utilizando a técnica de normalização Min-Max.

$$X' = \frac{X - \min(X)}{\max(X) - \min(X)} \quad (1)$$

Com o treinamento concluído foi traçado a curva ROC (Fig. 4) obtida pelo Regressor Logístico. O resultado apresentou um desempenho próximo a um classificador ideal.




Figura 4: Curva ROC.

A seguir iremos observar a influencia do *threshold* de decisão em relação ao F1-Score.




Figura 5: F1-Score em relação ao *threshold*.

O gráfico acima (Fig. 5) demonstra uma variação no F1-Score, conforme aumentamos o *threshold* de decisão. O valor de F1-Score tende a aumentar até o limiar de *threshold* = 0.6041. A partir deste ponto, conforme aumentamos o valor, o F1-Score tende a diminuir até zerar, no momento em que o *threshold* de decisão iguala a 1.

c)

O F1-Score define a qualidade do modelo baseado na sua precisão e a relação entre as medidas verdadeiras positivas e falso negativas (recall). Dessa forma, foi escolhido o *threshold* de decisão que maximizasse o valor de F1-Score, ou seja *threshold* = 0.6041. O que resultou num valor de F1-Score = 0.9707.

Com isso, frente aos dados de validação, o modelo apresentou uma acurácia de 96.53% e a seguinte matriz de confusão (Fig. 6). Este resultado apresenta uma ótima precisão e uma alta certeza nas medidas.




Figura 6: Matriz de Confusão, 0 representa o gênero Feminino e 1 o Masculino.

## Parte 2 – Classificação multi-classe

Nesta parte iremos treinar 2 modelos para caracterizar a atividade de uma pessoa através de 561 atributos. Esta atividade será diferenciada entre 6 modos:

- Caminhada
- Subindo Escadas
- Descendo Escadas
- Sentado
- Em pé
- Deitado

a)

Assim como na Parte 1, utilizaremos o modelo de Regressão Logística para prever as atividades. Entretanto, nessa etapa será utilizado a abordagem de *Softmax* para quantizar a

probabilidade da classificação de cada classe, em cada uma das predições. Em outras palavras, o modelo de *Softmax* irá retornar uma porcentagem de chance de cada classe ser a predita de acordo com os dados de entrada.

Com o modelo treinado, podemos observar a Matriz de Confusão gerada a partir dos dados de teste.




Figura 7: Matriz de Confusão da Regressão Logística.

A Matriz de Confusão obtida (Fig. 7) demonstra que o modelo resultou em boas predições, obtendo maiores erros na predição da pessoas estarem Sentadas e Subindo escadas, no qual o modelo previu que elas estariam em Pé e Caminhando, respectivamente.

Para a análise de desempenho do classificador de multi-classe, iremos observar os seguintes valores:

- Zero-One Loss : Corresponde ao conjunto de perca de cada amostra, no qual 0 representa que todo conjunto de rotulos foi feito de forma correta e 1, totalmente incorreto.
- F1-Score Micro : Cálculo de F1-Score considerando o total de verdadeiros positivos, falso negativos e falso positivos.
- F1-Score Macro : Cálculo de F1-Score para cada classe e tirando sua média não ponderada.
- Balanced Accuracy : Acurácia balanceada, definida como a média de Recall obtido para cada Classe.

Como podemos observar abaixo, o modelo de Regressão Logistica com *Softmax* apresentou uma ótima acurácia e precisão na classificação de multi-classe.

Zero-One Loss = 0.0417  
F1-Score Micro = 0.9583  
F1-Score Macro = 0.9581  
Balanced Accuracy = 0.9572

b)

Nesta etapa iremos treinar um modelo utilizando a técnica de *k-nearest neighbors*(KNN) para realizar as mesmas predições.

Inicialmente iremos observar a influência do valor de k vizinhos no modelo KNN.

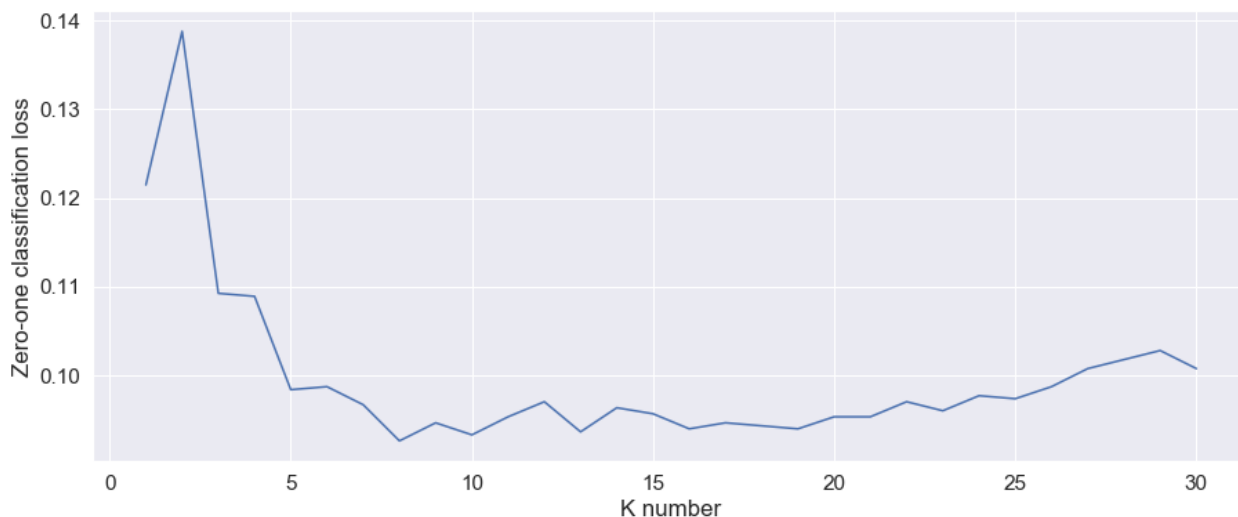


Figura 8: Resultado do treinamento com diferentes k vizinhos.

Como podemos observar na Figura 8, o modelo possui uma variação no erro de predição conforme aumentamos o valor de k vizinhos. Esta curva tem um mínimo em  $k = 8$  e tende a aumentar conforme aumentamos o valor de k.

Sendo assim, foi escolhido o valor de  $k=8$  para a predição do modelo. Este valor resultou na matriz de confusão apresentada na Figura 9.






Figura 9: Matriz de Confusão da técnica de KNN.

Abaixo podemos observar o desempenho do modelo pelas as métricas de desempenho apresentadas no item a).

Zero-One Loss = 0.0926  
 F1-Score Micro = 0.9074  
 F1-Score Macro = 0.9045  
 Balanced Accuracy = 0.9028

## Comparação

Matriz de confusão




Figura 10: Matrizes de Confusão

Podemos observar na Figura 10 que apesar da técnica KNN apresentar um bom resultado, a Regressão Logística ainda teve um desempenho melhor, apresentando um menor numero de classificações incorretas.

Abaixo, na Tabela 1, observamos que o modelo de Regressão Logística com *Softmax* se sobressai no desempenho da classificação de multi-classe quando comparado com a técnica de *K-Nearest Neighbors*. Porém, mesmo tendo um desempenho inferior, o KNN ainda apresentou uma ótima acurácia e confiança em suas predições.

Tabela 1: Comparação de desempenho

	Zero-One Loss	F1-Score Micro	F1-Score Macro	Balanced Accuracy
Regressão Logística	<b>0.0417</b>	<b>0.9583</b>	<b>0.9581</b>	<b>0.9572</b>
K-Nearest Neighbors	0.0926	0.9074	0.9045	0.9028